

G1 运动控制 (AI 翻译版, 原版为 report.pdf)

李子墨

学号 241098038

3234454007@qq.com

摘要

我使用 PPO 为宇树 G1 人形机器人训练了速度跟踪策略，并在此基础上实现了目标点跟踪。此外，我针对策略的两类分布外（OOD）场景——OOD 速度与 OOD 地形——进行了实验，并通过微调克服了相应的失败。

1 引言

目标是在 Isaac Lab 中让宇树 G1 走到指定目标点。我分两步完成。

训练：使用 PPO 训练速度跟踪策略。其指令为 (v_x, v_y, ω_z) ，其中 v_x 为前进速度， v_y 为侧向速度， ω_z 为转向角速度。

推理：固定已训练策略。用简单的比例控制器将相对目标位置转换为速度指令，策略再跟踪该指令以到达目标。

我还在两类超出训练分布的情形下测试策略：

- **更快指令：**基础策略在 $v_x \in [0, 1]$ m/s 下训练，测试时速度最高至 2 m/s。
- **崎岖地形：**将平地策略在楼梯、箱子、斜坡与高度噪声等地形上测试并微调。

在录制测试中，基础策略在 $v_x = 1.4$ m/s 时跌倒，而微调后的策略可在 2 m/s 下行走。经短暂的崎岖地形微调后，策略也能在无高度扫描的情况下走过所测的不规则地面。

2 相关工作

双足运动。 经典双足控制器常借助 SLIP [Blickhan, 1989]、LIP [Kajita et al., 2001]、ZMP [Vukobratović and Borovac, 2004] 等简化模型规划稳定运动。这类方法直接建模平衡，但需要精心设计的控制器。

学习运动。 深度强化学习可直接从仿真经验中学习运动。借助数千个并行环境，速度跟踪策略可被高效训练 [Rudin et al., 2022]。我沿用该方法训练 G1。

训练工具。 PPO 是一种 actor-critic 算法，通过裁剪目标限制每次策略更新幅度 [Schulman et al., 2017]。我使用 RSL-RL 中的 PPO、Isaac Sim 的 GPU 并行物理，以及 Isaac Lab 中的 G1 机器人与运动环境。

3 训练

我在 Isaac Lab 中仿真树 G1，并用 PPO (RSL-RL) 训练速度跟踪策略。4096 个环境在 GPU 上并行运行；每一步策略输出关节目标，物理仿真推进，并收集奖励用于更新。策略跟踪随机采样的指令 $\mathbf{c}_t = (v_x, v_y, \omega_z)$ 。

3.1 MDP

学习目标是使 G1 跟随指令平面速度 $\mathbf{c}_t = (v_x, v_y, \omega_z)$ 。我使用官方平地任务 `G1FlatEnvCfg`，并关闭其高度扫描仪。一个控制步流程如下：策略观测机器人与当前指令，为每个主动关节输出目标偏移；随后仿真器推进物理，并评估运动对指令的跟踪效果。

形式上，仿真器状态 s_t 包含机器人与环境的完整物理状态。策略并不直接接收 s_t ，而是接收 123 维观测

$$\mathbf{o}_t = [\mathbf{v}_t^b, \boldsymbol{\omega}_t^b, \mathbf{g}_t^b, \mathbf{c}_t, \mathbf{q}_t - \mathbf{q}_0, \dot{\mathbf{q}}_t, \mathbf{a}_{t-1}], \quad \mathbf{o}_t \in \mathbb{R}^{123}.$$

其中， $\mathbf{v}_t^b$ 与 $\boldsymbol{\omega}_t^b$ 分别为基座线速度与角速度（各 3 维）， $\mathbf{g}_t^b$ 为基座坐标系下的重力方向（3 维）， $\mathbf{c}_t$ 为速度指令（3 维）。其余项为相对默认姿态的 37 个关节位置、37 个关节速度，以及上一时刻的 37 维动作。维度合计 $3 + 3 + 3 + 3 + 37 + 37 + 37 = 123$ 。训练时对机体与关节测量加入小幅均匀噪声。由于关闭了高度扫描仪，策略无法直接获得地形描述。

动作与转移。 动作 $\mathbf{a}_t \in \mathbb{R}^{37}$ 并不直接指定关节力矩，而是相对默认姿态的位置偏移：

$$\mathbf{q}_t^{\text{target}} = \mathbf{q}_0 + 0.5 \mathbf{a}_t.$$

关节控制器跟踪这些目标，同时 Isaac Sim 将机器人动力学从 s_t 推进到 s_{t+1} 。将 $\mathbf{a}_{t-1}$ 纳入下一步观测，使策略在生成平滑动作序列时能考虑上一目标。

奖励与终止。 奖励为官方 G1 平地任务给出的加权和。最大的正向项奖励跟踪指令 XY 速度与偏航角速度（权重各 +1.0）。足部腾空时间项（+0.75）鼓励迈步。惩罚项抑制足部滑动（-0.1）、身体倾斜（-1.0）、竖直速度（-0.2）、滚转与俯仰角速度（-0.05），以及关节偏离或越限（权重从 -1.0 到 -0.05）。较小的正则项惩罚动作剧烈变化（ -5×10^{-3} ）、关节力矩（ -2×10^{-6} ）与关节加速度（ -1×10^{-7} ）。终止时奖励为 -200。因此，最大化回报要求机器人跟随指令，同时保持稳定、平滑且物理上合理的步态。

PPO 配置。 Actor 与 critic 使用隐藏层为 [256, 128, 128] 的 MLP。PPO 每次迭代从 4096 个并行环境各采集 24 步，裁剪参数 0.2，折扣因子 $\gamma = 0.99$ ，GAE 参数 $\lambda = 0.95$ ，熵系数 0.008。


3.2 速度策略训练

我训练一个策略，使其在平地上跟随随机采样的速度指令。指令范围为

$$v_x \in [0, 1] \text{ m/s}, \quad v_y \in [-0.5, 0.5] \text{ m/s}, \quad \omega_z \in [-1, 1] \text{ rad/s},$$

其中 v_x 控制前进， v_y 控制侧向， ω_z 控制转向。少量环境收到站立指令 $\mathbf{c}_t = \mathbf{0}$ ，因此同一策略也学会保持静止。训练共 1750 次迭代。图 1 显示平均奖励稳步上升、速度跟踪误差下降；图 2 展

示平面上的步态结果。



平均奖励。

速度跟踪误差。

图 1: 基础速度策略训练曲线。




图 2: 训练得到的速度跟踪策略在平地上（随机指令）。

4 推理

推理时固定策略权重，用比例控制器将目标位移转换为 (v_x, v_y, ω_z) 。策略以与训练相同的观测与动作空间跟踪这些指令。

目标到速度的控制器。 每个控制步，将世界坐标系下的目标表示到机器人偏航坐标系中为 (d_x, d_y) 。角度 $\psi = \text{atan2}(d_y, d_x)$ 为该坐标系下机器人到目标的方向。速度指令按如下计算：

1. 若 $\sqrt{d_x^2 + d_y^2} < 0.35 \text{ m}$ ，令 $\mathbf{c}_t = \mathbf{0}$ ，使机器人在目标附近站立。
2. 否则，施加比例控制：

$$v_x = \text{clip}(k_\ell d_x, 0, 1), \quad v_y = \text{clip}(k_\ell d_y, -0.5, 0.5), \quad \omega_z = \text{clip}(k_a \psi, -1, 1),$$

其中 $k_\ell = 1.0$ ， $k_a = 1.5$ 。

裁剪使每条指令落在训练所见范围内。特别地，控制器从不请求后退；当目标在机器人后方时，偏航控制先转向目标，再发出明显的前进指令。

结果。在录制仿真中，冻结策略走向标记目标，并在进入 0.35 m 停止区域后站立（图 3）。




图 3: 目标导向推理。比例控制器引导冻结的速度策略走向绿色标记。

5 探索实验一：前进速度泛化

基础策略训练时前进指令不超过 1 m/s。本实验考察其收到更快指令时的表现，以及微调能否扩展可用速度范围。机器人、地形、观测与动作保持不变；仅前进指令幅值超出原训练分布。


5.1 微调

宽 v_x 策略由基础策略初始化，并在前进指令最高 2 m/s 下微调；网络结构与目标控制器保持不变。侧向与偏航指令范围收窄，以强调前进运动：

策略	v_x (m/s)	v_y (m/s)	ω_z (rad/s)
基础	$[0, 1]$	$[-0.5, 0.5]$	$[-1, 1]$
宽 v_x	$[0, 2]$	$[-0.2, 0.2]$	$[-0.5, 0.5]$

表 1: 训练两种策略所用的指令分布。

该指令分布使微调聚焦于前进运动。图 4 显示平均奖励回升，速度跟踪误差下降。



平均奖励。

速度跟踪误差。

图 4: 宽 v_x 微调曲线。


5.2 评估协议

两种策略均接收固定、纯前进指令 $\mathbf{c} = (v_x, 0, 0)$ 。扫描覆盖 0.2 至 2.0 m/s；不超过 1.0 m/s 的指令对基础策略为分布内，1.1 至 2.0 m/s 为分布外。关闭自动航向指令与站立环境，使受测变量仅为指令前进速度。


我在每个速度下录制仿真片段，比较机器人是否保持直立并跟随指令。

5.3 观测结果


在录制扫描中，基础策略在 $v_x = 1.3 \text{ m/s}$ 时仍能直立，但在 1.4 m/s 及更高测试指令下跌倒。微调后，宽 v_x 策略在直至 2.0 m/s 时仍保持直立并跟随前进指令。因此，微调将所测指令范围扩展到超出基础策略。




基础， $v_x = 1.3 \text{ m/s}$ （稳定）。



基础， $v_x = 1.4 \text{ m/s}$ （跌倒）。



宽 v_x ， $v_x = 1.4 \text{ m/s}$ 。



宽 v_x ， $v_x = 2.0 \text{ m/s}$ 。

图 5: OOD 前进速度帧。基础策略在 $v_x = 1.3 \text{ m/s}$ 时保持，但在 $v_x = 1.4 \text{ m/s}$ 时倒下；宽 v_x 在 $v_x = 1.4 \text{ m/s}$ 时恢复，并在 $v_x = 2.0 \text{ m/s}$ 时仍能行走。

6 探索实验二：崎岖地形微调

本实验考察平地 G1 速度策略能否在不改变观测维度的前提下迁移到不规则地面，从而使预训练权重仍可兼容加载。

6.1 动机

官方崎岖地形（楼梯、随机箱子、高度噪声、斜坡）通常在策略观测中带有高度扫描仪。平地策略无高度扫描（123 维）。启用扫描仪会改变网络输入尺寸，预训练检查点将无法加载。能否在关闭高度扫描的情况下，仅对崎岖物理进行微调，仍获得可用的行走？

6.2 设置

项目	选择
地形	ROUGH_TERRAINS_CFG + 从 level 0 开始的课程
观测	与平地相同：无 <code>height_scan</code>
初始化	基础平地速度策略（非宽 v_x 策略）
指令	$v_x \in [0, 2]$, $v_y \in [-0.5, 0.5]$, $\omega_z \in [-1, 1]$
奖励	官方 G1 崎岖： <code>lin_vel_z_12 = 0</code>
环境数	4096

表 2: 崎岖地形微调设置。


微调从基础平地策略开始，因此同时将前进指令范围扩大到 $[0, 2]$ m/s 并更换地形。竖直速度惩罚 `lin_vel_z_12` 设为零，因为上下楼梯需要基座竖直运动，平地奖励会对此加以惩罚。

6.3 训练

平地策略在崎岖地形上微调 351 次迭代。图 6 显示平均 episode 长度上升并稳定在约 850 个控制步附近，同时地形课程从 level 1 升至约 3.4。



平均 episode 长度。



地形课程等级。

图 6: 崎岖地形微调：episode 长度与课程进度。

6.4 结果

微调后，策略可在无高度扫描的情况下走过楼梯、随机箱子、斜坡与高度噪声。在部分更难的地块上仍会跌倒，因为它无法预知前方地形，只能在接触后作出反应。更多训练或许有帮助，但 GPU 当时另有安排。




图 7: 微调后的崎岖地形演示。策略在无高度扫描的情况下穿越楼梯、随机箱子、高度噪声与斜坡。

7 总结

主要结论是：速度策略可复用于目标跟踪——简单的比例控制器生成速度指令，学习到的策略负责行走。实验也表明训练分布至关重要。微调将所测前进速度从 1.3 m/s 扩展到 2.0 m/s ，并使平地策略在不改变观测尺寸的情况下能在崎岖地形上行走。

主要局限在于：速度与崎岖地形结果基于定性视频，而非重复试验或数值基准。崎岖策略仅短暂微调且无高度扫描，因而无法看见前方地形。我仅在仿真中评估策略。

参考文献

- Reinhard Blickhan. The spring-mass model for running and hopping. *Journal of Biomechanics*, 22 (11-12):1217–1227, 1989.
- Shuuji Kajita, Fumio Kanehiro, Kenji Kaneko, Kazuhito Yokoi, and Hirohisa Hirukawa. The 3d linear inverted pendulum mode: A simple modeling for a biped walking pattern generation. In *Proceedings of the 2001 IEEE/RSJ International Conference on Intelligent Robots and Systems*, volume 1, pages 239–246, 2001.
- Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning. *Conference on Robot Learning*, 2022.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Miomir Vukobratović and Branislav Borovac. Zero-moment point—thirty five years of its life. *International Journal of Humanoid Robotics*, 1(01):157–173, 2004.